Entrega Examen CEIPA

Punto 1 – DIAGNOSTICO DE FUENTES

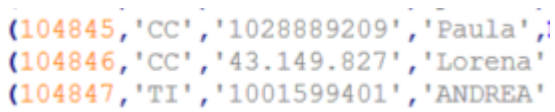
Se hace entrega del Diagnóstico de fuentes por medio de un archivo de Excel llamado "DiagnosticoFuentes" el cual contiene dos pestañas, una contiene el "Inventario de fuentes" y en la otra "Diccionario de Datos" el cual tiene los respectivos filtros para buscar los campos en cada una de las fuentes de SIAC, VentasCloud y ContaPlus.

Punto 2 – HALLAZGOS DE CALIDAD

ID: 1

Hallazgo: Formatos diferentes para números de documento

Evidencia: En SIAC_PERS, el campo NUM_DOC aparece con valores como 43.149.827 y 1028889209.



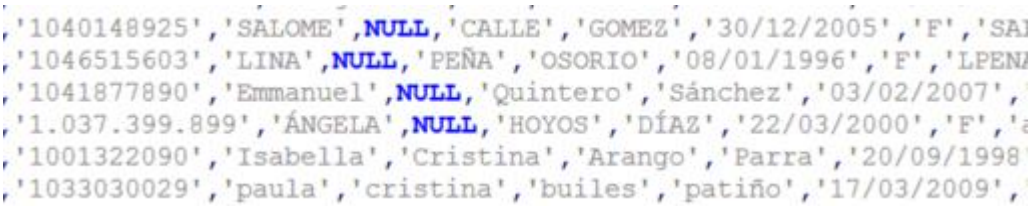
Impacto Analítico: Cuando se compara el campo con otras fuentes puede existir diferentes representaciones del mismo número y por ende no cruzar la información o puede generar duplicado de información.

Propuesta Corrección: Se debería de considerar reglas de limpieza como por ejemplo eliminar los puntos, espacios en blanco, guiones, etc., en etapas posteriores del proceso con el fin de preservar el dato original.

ID: 2

Hallazgo: Inconsistencia en mayúsculas y minúsculas

Evidencia: En SIAC_PERS, los campos PRI_NOM,SEG_NOM,PRI_APE,SEG_APE aparece con valores mayúsculas y minúsculas.



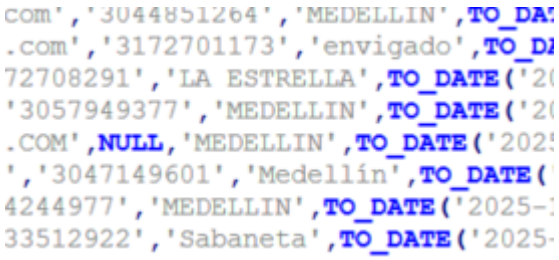
Impacto Analítico: Agrupaciones, búsquedas y comparaciones de nombres pueden producir resultados inconsistentes.

Propuesta Corrección: Se debería de considerar reglas de transformación con el fin de tener toda la información en mayúscula o minúscula con el fin de obtener integridad de datos y este cambio de realizaría en etapas de transformación con el fin de preservar el dato original.

ID: 3

Hallazgo: Variaciones en los nombres de municipios

Evidencia: En SIAC_PERS, Se encuentran variantes como Medellín, MEDELLIN, medellin y Itagui.



Impacto Analítico: Pueden presentarse problemas de integridad cuando se desee consultar la información por segmentación geográfica

Propuesta Corrección: Homologar con un catálogo institucional de municipios y departamentos conservando el valor de origen.

CORRECCION TECNICA Y ACUERDOS CON LA AREAS

ID1 -> Definir el formato de numero de identificación oficial de persona y las reglas de excepción.

ID2 -> Definir la forma correcta que se debe de mostrar los datos en los informes que se deseen generar.

ID3 -> Aprobar el catálogo geográfico con el fin de realizar unicidad de municipios.

NOTA:

EXISTEN MUCHAS MAS EVIDENCIAS DE CALIDAD PARA CADA UNA DE LAS FUENTES, PERO POR TIEMPOS DE ENTREGA SOLO SE ENVIA UNA PEQUEÑA MUESTRA.

Punto 3 – PROPUESTA DE GOBIERNO DE DATOS

Propongo un modelo donde se involucren las áreas mencionadas dueñas de la información y también el área de TI.

Dueños, roles y responsabilidades

Rol	Responsabilidad	Areas Responsables
Dueño de datos académicos	Definir las reglas de estudiantes, matrículas, programas y calificaciones.	Líder de Conocimiento Registro y Control
Dueño de datos comerciales	Definir clientes, ventas, estados y reglas de negocio comercial.	Líder de Conocimiento Comercial
Dueño de datos financieros	Definir recaudos, cartera, conceptos y conciliaciones.	Líder de Conocimiento Financiero
Administrador de Información Técnica	Administrar las fuentes de información y la entrega desde la parte técnica	TI
Responsable de Ingeniería de Datos	Implementar la creación y ajustes a los modelos de información	TI-Equipo de datos
Responsables de Calidad de Información(TI-Funcionales)	Realizar la revisión de la información entregada por el ingeniero de datos desde lo técnico y lo funcional	Responsables funcionales con apoyo del equipo de datos.

Definiciones de negocio

Se debe construir un glosario de los términos y definiciones aprobadas dentro del modelo construido con el fin de unificar los conceptos de cada termino existente dentro de la implementación. ejemplo

Termino	Definicion Propuesta	Responsables del termino
Persona	Individuo identificado por un conjunto de atributos personales y una identidad institucional.	Los dueños de los datos de cada area involucrada (Registro y control, Comercial y Financiera)
Estudiante	Persona que cumple las condiciones institucionales para ser considerada estudiante.	Registro y control
Recaudo	Movimiento que representa un pago recibido y registrado conforme a las reglas contables.	Financiero
Venta efectiva	Operación que cumple los criterios comerciales y financieros aprobados para contabilizarse como efectiva.	Comercial

NOTA:

El anterior cuadro de definiciones solo muestra unos pocos conceptos a modo de ejemplo.

Identificar a una misma persona en los tres sistemas

Para identificar una misma persona primero hay que limpiar la información de cada uno de los sistemas, por ejemplo en el tipo y numero de documento se deben de aplicar reglas que normalicen el registro para luego dentro del modelo dimensional generar unificación de información, para lo cual generaría una tabla DIM_PERSONA independiente de cual fuente de datos provenga.

Punto 4 – ARQUITECTURA OBJETIVO EN AZURE

Propongo una arquitectura Medallion donde existan 3 capas para la entrega, transformacion y carga del modelo dimensional, estas capas son Bronze, Silver y Gold.

CAPA BRONZE

En esta capa se entrega la información cruda, por ejemplo los archivos: siac_export_YYYY_MM_DD.sql, respuesta_endpoint_clientes.json, recaudos_YYYY_MM.txt, cartera_corte_YYYY_MM.txt con el fin de preservar la información recibida de manera original.

CAPA SILVER (Datos estandarizados y validados)

Aquí se convierten los datos a estructuras tipadas y se aplican reglas técnicas.

Ejemplos:

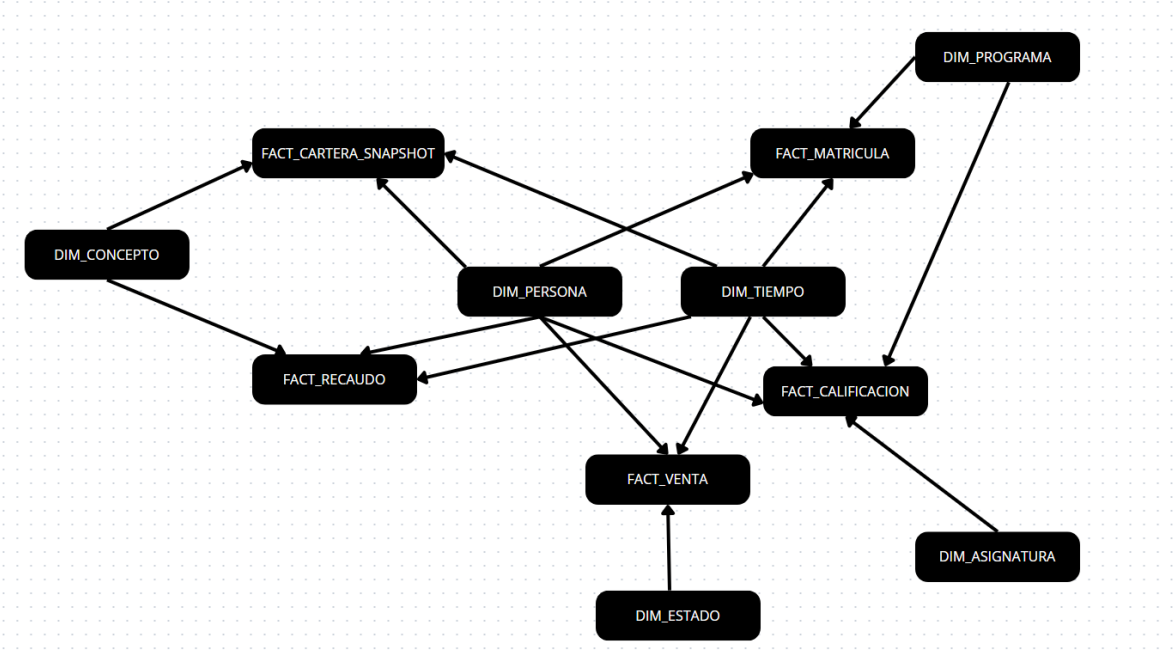
- siac_personas.
- siac_matriculas.
- siac_calificaciones.
- ventascloud_clientes.
- ventascloud_ventas.
- contaplus_recaudos.
- contaplus_cartera.
- contaplus_conceptos.

Se sugiere que los datos que tengan problemas se deben de reportar a una tabla log donde se registre el motivo de rechazo con el fin de tener control de los datos ingestados en las capas bronze y silver.

CAPA GOLD (Modelo Dimensional)

Se propone un modelo dimensional que contengas estas tablas de dimensiones
- DIM_PERSONA
- DIM_TIEMPO
- DIM_PROGRAMA
- DIM_ASIGNATURA
- DIM_CONCEPTO
- DIM_ESTADO

Y las siguientes tablas de hechos
- FACT_MATRICULA
- FACT_CALIFICACION
- FACT_VENTA
- FACT_RECAUDO
- FACT_CARTERA_SNAPSHOT



Este modelo se compone de 5 modelos estrella con el fin de suplir las necesidades de cada una de las 3 áreas impactadas.