Entrega Examen CEIPA

Punto 1 – DIAGNOSTICO DE FUENTES

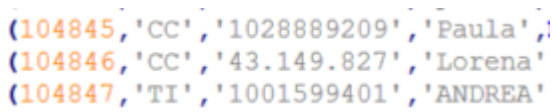
Se hace entrega del Diagnóstico de fuentes por medio de un archivo de Excel llamado "DiagnosticoFuentes" el cual contiene dos pestañas, una contiene el "Inventario de fuentes" y en la otra "Diccionario de Datos" el cual tiene los respectivos filtros para buscar los campos en cada una de las fuentes de SIAC, VentasCloud y ContaPlus.

Punto 2 – HALLAZGOS DE CALIDAD

ID: 1

Hallazgo: Formatos diferentes para números de documento

Evidencia: En SIAC_PERS, el campo NUM_DOC aparece con valores como 43.149.827 y 1028889209.



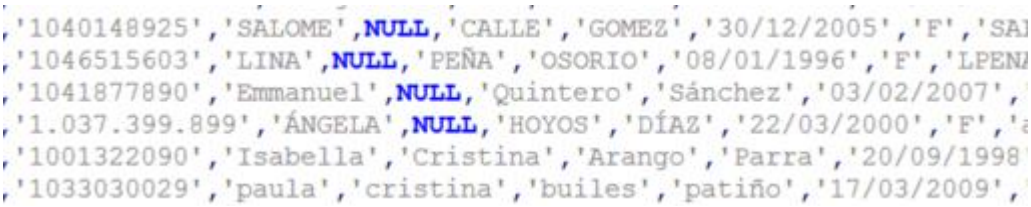
Impacto Analítico: Cuando se compara el campo con otras fuentes puede existir diferentes representaciones del mismo número y por ende no cruzar la información o puede generar duplicado de información.

Propuesta Corrección: Se debería de considerar reglas de limpieza como por ejemplo eliminar los puntos, espacios en blanco, guiones, etc., en etapas posteriores del proceso con el fin de preservar el dato original.

ID: 2

Hallazgo: Inconsistencia en mayúsculas y minúsculas

Evidencia: En SIAC_PERS, los campos PRI_NOM,SEG_NOM,PRI_APE,SEG_APE aparece con valores mayúsculas y minúsculas.



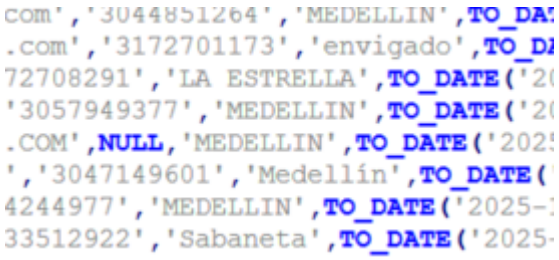
Impacto Analítico: Agrupaciones, búsquedas y comparaciones de nombres pueden producir resultados inconsistentes.

Propuesta Corrección: Se debería de considerar reglas de transformación con el fin de tener toda la información en mayúscula o minúscula con el fin de obtener integridad de datos y este cambio de realizaría en etapas de transformación con el fin de preservar el dato original.

ID: 3

Hallazgo: Variaciones en los nombres de municipios

Evidencia: En SIAC_PERS, Se encuentran variantes como Medellín, MEDELLIN, medellin y Itagui.



Impacto Analítico: Pueden presentarse problemas de integridad cuando se desee consultar la información por segmentación geográfica

Propuesta Corrección: Homologar con un catálogo institucional de municipios y departamentos conservando el valor de origen.

CORRECCION TECNICA Y ACUERDOS CON LA AREAS

ID1 -> Definir el formato de numero de identificación oficial de persona y las reglas de excepción.

ID2 -> Definir la forma correcta que se debe de mostrar los datos en los informes que se deseen generar.

ID3 -> Aprobar el catálogo geográfico con el fin de realizar unicidad de municipios.

NOTA:

EXISTEN MUCHAS MAS EVIDENCIAS DE CALIDAD PARA CADA UNA DE LAS FUENTES, PERO POR TIEMPOS DE ENTREGA SOLO SE ENVIA UNA PEQUEÑA MUESTRA.

Punto 3 – PROPUESTA DE GOBIERNO DE DATOS

Propongo un modelo donde se involucren las áreas mencionadas dueñas de la información y también el área de TI.

Dueños, roles y responsabilidades

Rol	Responsabilidad	Areas Responsables
Dueño de datos académicos	Definir las reglas de estudiantes, matrículas, programas y calificaciones.	Líder de Conocimiento Registro y Control
Dueño de datos comerciales	Definir clientes, ventas, estados y reglas de negocio comercial.	Líder de Conocimiento Comercial
Dueño de datos financieros	Definir recaudos, cartera, conceptos y conciliaciones.	Líder de Conocimiento Financiero
Administrador de Información Técnica	Administrar las fuentes de información y la entrega desde la parte técnica	TI
Responsable de Ingeniería de Datos	Implementar la creación y ajustes a los modelos de información	TI-Equipo de datos
Responsables de Calidad de Información(TI-Funcionales)	Realizar la revisión de la información entregada por el ingeniero de datos desde lo técnico y lo funcional	Responsables funcionales con apoyo del equipo de datos.

Definiciones de negocio

Se debe construir un glosario de los términos y definiciones aprobadas dentro del modelo construido con el fin de unificar los conceptos de cada termino existente dentro de la implementación. ejemplo

Termino	Definicion Propuesta	Responsables del termino
Persona	Individuo identificado por un conjunto de atributos personales y una identidad institucional.	Los dueños de los datos de cada area involucrada (Registro y control, Comercial y Financiera)
Estudiante	Persona que cumple las condiciones institucionales para ser considerada estudiante.	Registro y control
Recaudo	Movimiento que representa un pago recibido y registrado conforme a las reglas contables.	Financiero
Venta efectiva	Operación que cumple los criterios comerciales y financieros aprobados para contabilizarse como efectiva.	Comercial

NOTA:

El anterior cuadro de definiciones solo muestra unos pocos conceptos a modo de ejemplo.

Identificar a una misma persona en los tres sistemas

Para identificar una misma persona primero hay que limpiar la información de cada uno de los sistemas, por ejemplo, en el tipo y numero de documento se deben de aplicar reglas que normalicen el registro para luego dentro del modelo dimensional generar unificación de información, para lo cual generaría una tabla DIM_PERSONA independiente de cual fuente de datos provenga.

Punto 4 – ARQUITECTURA OBJETIVO EN AZURE

Propongo una arquitectura Medallion donde existan 3 capas para la entrega, transformacion y carga del modelo dimensional, estas capas son Bronze, Silver y Gold.

CAPA BRONZE

En esta capa se entrega la información cruda, por ejemplo los archivos: siac_export_YYYY_MM_DD.sql, respuesta_endpoint_clientes.json, recaudos_YYYY_MM.txt, cartera_corte_YYYY_MM.txt con el fin de preservar la información recibida de manera original.

CAPA SILVER (Datos estandarizados y validados)

Aquí se convierten los datos a estructuras tipadas y se aplican reglas técnicas.

Ejemplos:

- siac_personas.
- siac_matriculas.
- siac_calificaciones.
- ventascloud_clientes.
- ventascloud_ventas.
- contaplus_recaudos.
- contaplus_cartera.
- contaplus_conceptos.

Se sugiere que los datos que tengan problemas se deben de reportar a una tabla log donde se registre el motivo de rechazo con el fin de tener control de los datos ingestados en las capas bronze y silver.

CAPA GOLD (Modelo Dimensional)

Se propone un modelo dimensional que contengas estas tablas de dimensiones
- DIM_PERSONA
- DIM_TIEMPO
- DIM_PROGRAMA
- DIM_ASIGNATURA
- DIM_CONCEPTO
- DIM_ESTADO

Y las siguientes tablas de hechos
- FACT_MATRICULA
- FACT_CALIFICACION
- FACT_VENTA
- FACT_RECAUDO
- FACT_CARTERA_SNAPSHOT

A continuación, se entrega una breve descripción de los campos a implementar en la capa Gold para el modelo dimensional de datos

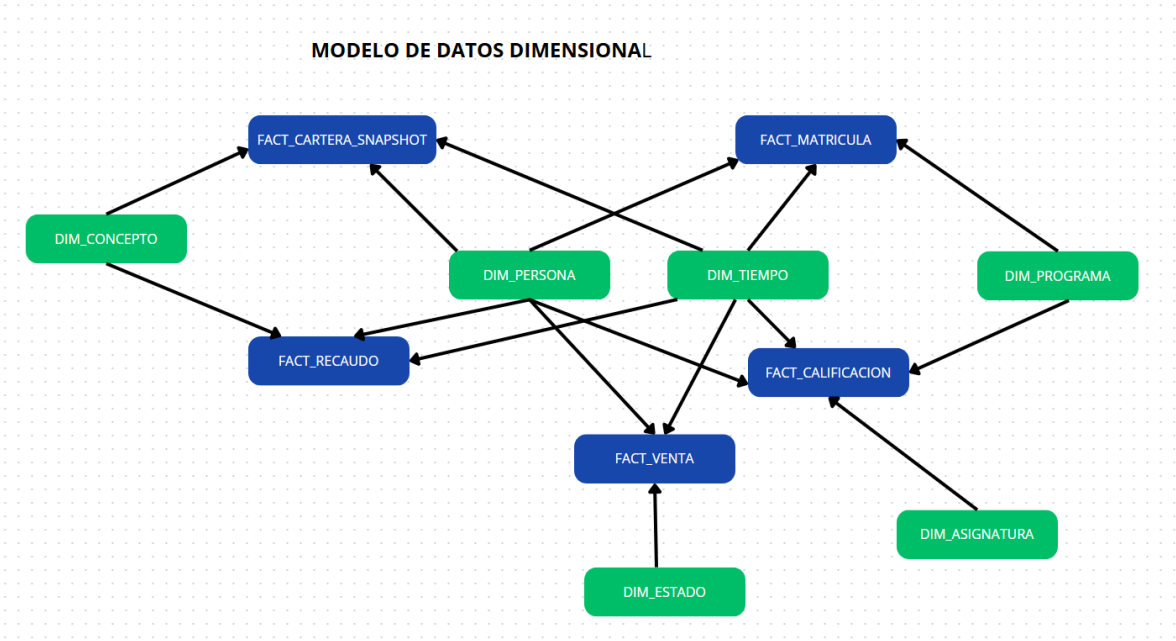
CAMPOS DIMENSIONES

DIM_PERSONA	DIM_TIEMPO	DIM_PROGRAMA	DIM_ASIGNATURA	DIM_CONCEPTO	DIM_ESTADO
PERSONA_ID(PK)	FECHA_ID(PK)	PROGRAMA_ID(PK)	ASIGNATURA_ID(PK)	CONCEPTO_ID(PK)	ESTADO_ID(PK)
TIPO_DOCUMENTO	FECHA	COD_PROG_ORIGEN	COD_ASIG_ORIGEN	COD_CONCEPTO_ORIGEN	SISTEMA_ORIGEN
NUM_DOCUMENTO	DIA	NOMBRE_PROGRAMA	NOMBRE_ASIG	NOMBRE_CONCEPTO	COD_ESTADO_ORIGEN
NOMBRE_COMPLETO	MES	COD_SNIES	ESTADO_ASIG	CATEGORIA_CONCEPTO	DESCRIPCION_ORIGEN
FECHA_NACIMIENTO	NOMBRE_MES	ESTADO_PROGRAMA	FECHA_INICIO_VIGENCIA	ESTADO_CONCEPTO	ESTADO_HOMOLOGADO
MUNICIPIO	TRIMESTRE	FECHA_INICIO_VIGENCIA	FECHA_FIN_VIGENCIA	FECHA_INICIO_VIGENCIA	ES_ESTADO_VIGENTE
ESTADO_ID	ANIO	FECHA_FIN_VIGENCIA	ES_REGISTRO_ACTUAL	FECHA_FIN_VIGENCIA	
FECHA_INICIO_VIGENCIA	DIA_SEMANA	ES_REGISTRO_ACTUAL		ES_REGISTRO_ACTUAL	
FECHA_FIN_VIGENCIA	ES_FIN_SEMANA				
ES_REGISTRO_ACTUAL	PERIODO_ACADEMICO				

CAMPOS TABLAS DE HECHOS

FACT_MATRICULA	FACT_CALIFICACION	FACT_VENTA	FACT_RECAUDO	FACT_CARTERA_SNAPSHOT
MATRICULA_ID	CALIFICACION_ID(PK)	VENTA_ID(PK)	RECAUDO_ID(PK)	CARTERA_ID(PK)
ID_MATR_ORIGEN	ID_CALIF_ORIGEN	ID_VENTA_ORIGEN	ID_RECAUDO_ORIGEN	PERSONA_ID(FK)
PERSONA_ID(FK)	PERSONA_ID(FK)	NUM_LINEA	PERSONA_ID(FK)	CONCEPTO_ID(FK)
PROGRAMA_ID(FK)	PROGRAMA_ID(FK)	PERSONA_ID(FK)	CONCEPTO_ID(FK)	FECHA_CORTE_ID(FK)
FECHA_MATRICULA(FK)	ASIGNATURA_ID(FK)	FECHA_VENTA_ID(FK)	RFECHA_RECAUDO_ID(FK)	SALDO_PENDIENTE
ESTADO_ID(FK)	FECHA_ID(FK)	ESTADO_VENTA_ID(FK)	VALOR_RECAUDO	CANTIDAD_REGISTROS
CANTIDAD_MATRICULAS	ESTADO_ID(FK)	CANTIDAD	CANTIDAD_RECAUDOS	ARCHIVO_ORIGEN
ES_MATRICULA_ACTIVA	NOTA_C1	VALOR_BRUTO	ARHCIVO_ORIGEN	ID_EJECUCION
FECHA_CARGA	NOTA_C2	VALOR_DESCUENTO	ID_EJECUCION	
ID_EJECUCION	NOTA_C3	VALOR_NETO		
	NOTAS_DEFINITIVA	ID_EJECUCION		
	ES_CALIFICACION_ANULADA			
	ID_EJECUCION			

Diagrama de Modelo Dimensional



Este modelo se compone de 5 modelos estrella con el fin de suplir las necesidades de cada una de las 3 áreas impactadas.